PORTAS ABERTAS 2026

A IA GOVERNADA: O CAMINHO PARA A INTRODUÇÃO DOS AGENTES NA ELICITAÇÃO DE REQUISITOS

Carlos Eduardo Moreira dos Santos[1], Gabriela de Moura Freitas[2], Giovana Pinheiro da Silva[3], Jéssica Guimarães dos Santos[4], Larissa Meneguello[5], Adani Cusin Sacilotti[6]

[1] Graduando em Tecnologia em Análise e Desenvolvimento de Sistemas, Fatec Jundiaí, carlos.santos35@aluno.cps.sp.gov.br
[2] Graduanda em Tecnologia em Análise e Desenvolvimento de Sistemas, Fatec Jundiaí, gabriela.freitas4@aluno.cps.sp.gov.br
[3] Graduanda em Tecnologia em Análise e Desenvolvimento de Sistemas, Fatec Jundiaí, giovana.silva27@aluno.cps.sp.gov.br
[4] Graduanda em Tecnologia em Análise e Desenvolvimento de Sistemas, Fatec Jundiaí, jessica.santos17@aluno.cps.sp.gov.br
[5] Graduanda em Tecnologia em Análise e Desenvolvimento de Sistemas, Fatec Jundiaí, larissa.meneguello@aluno.cps.sp.gov.br
[6] Docente em Tecnologia em Análise e Desenvolvimento de Sistemas, Fatec Jundiaí, prof_adani@yahoo.com.br

INTRODUÇÃO

Os debates sobre inteligência artificial tomaram conta do meio tecnológico e acadêmico, em especial pós-implementação do GPT-3 pela OpenAI em 2020. Hoje, seis anos depois, o salto exponencial dado pelas empresas que trabalham com essa tecnologia chama a atenção e os horizontes técnicos alcançados pelos principais agentes do mercado estão cada vez mais extensos. Paralelamente, a aceleração digital deflagrada nos últimos anos gerou uma proliferação de aplicações voltadas a nichos altamente específicos. Dessa convergência entre expansão massiva de software e a integração de agentes inteligentes, nasceu um problema quase ignorado e crítico, que talvez possa ser respondido com auxílio das tecnologias supracitadas: a elicitação de requisitos. Frequentemente, ocorre um desalinhamento entre as soluções idealizadas por programadores e a demanda real dos usuários finais, resultando em produtos com pouca tração no mercado por falhas no levantamento inicial de necessidades. Nesse contexto, este trabalho investiga como incorporar os conceitos de elicitação às boas práticas de desenvolvimento apoiadas por Inteligência Artificial. Para fundamentar a proposta, apresenta-se um estudo de caso prático no qual a IA é empregada desde a concepção de instrumentos de pesquisa e análise das respostas dos usuários, até o suporte contínuo na extração, especificação e validação dos requisitos que orientaram a primeira versão do sistema. Para isso, este artigo está organizado da seguinte forma: a seção 2 apresenta o referencial teórico sobre elicitação de requisitos e sobre o uso de inteligência artificial nesse processo, situando a lacuna explorada por este trabalho; a seção 3 apresenta o estudo de caso, descrevendo o método adotado e, em seguida, o desenvolvimento e os resultados obtidos com o uso da IA na concepção do instrumento de pesquisa e na análise das respostas; e, por fim, a seção 4 discute os resultados e aponta considerações finais e caminhos futuros de pesquisa.

REFERENCIAL TEÓRICO

A ELICITAÇÃO DE REQUISITOS

A elicitação de requisitos é o processo de descobrir, extrair e entender as necessidades, expectativas e restrições dos usuários e clientes para criar um sistema de software. Essa etapa do desenvolvimento é vital para a construção de um produto não só funcional, mas que tenha, também, alguma penetração com o público para o qual ele foi construído. O que chama a atenção é que hoje existe uma quantidade enorme de técnicas documentadas e usuais (mais ou menos) dentro da indústria. Alflen e Prado (2021) apontam para cerca de 40, que podem, inclusive, ser subdivididas, uma vez que

são refinadas e retrabalhadas a cada uso. Em contrapartida, Siddeshwar, Alwidian e Makrehchi (2024) levantaram cerca de 15 tarefas de elicitação que são suportadas por inteligência artificial.

Segundo Alflen e Prado (2021), que revisaram 61 artigos da base Scopus, as dez técnicas de elicitação mais citadas podem ser classificadas em três grupos, de acordo com a origem dos requisitos: individual, quando o requisito vem de um respondente por vez, caso do questionário; grupal, quando surge da interação simultânea entre vários stakeholders, como no brainstorming e no workshop; e mista, que combina as duas formas, caso da entrevista e da prototipação. Segundo as autoras, o questionário se destaca pelo baixo custo e pela facilidade de coletar dados de muitos stakeholders ao mesmo tempo, sendo comum nas fases iniciais do levantamento. Por outro lado, ele também tem limitações: por não permitir uma interação direta com o respondente, tende a gerar informações mais rasas sobre o contexto e as motivações por trás das respostas, o que pode prejudicar a qualidade dos requisitos levantados.

É justamente nesse ponto, no desenho do instrumento — na formulação das perguntas, na antecipação de ambiguidades e na estruturação de um roteiro capaz de captar necessidades que nem sempre são ditas de forma explícita — que está grande parte do esforço para reduzir as fraquezas do questionário. A literatura tradicional, no entanto, fala pouco sobre como esse desenho é feito na prática e por quem, tratando a elaboração do instrumento quase como um processo artesanal, dependente da experiência de quem conduz a pesquisa.

A INTELIGÊNCIA ARTIFICIAL APLICADA À ELICITAÇÃO DE REQUISITOS

A literatura mais recente também tem investigado o uso de inteligência artificial como apoio às atividades de elicitação. Siddeshwar, Alwidian e Makrehchi (2024) publicaram uma revisão sistemática, na IEEE Access, que mapeou estudos com uso de aprendizado de máquina e processamento de linguagem natural em diferentes tarefas do processo de elicitação. Os autores identificaram cerca de quinze dessas tarefas, além das principais fontes de dados usadas para treinar e avaliar os modelos propostos. Segundo eles, apesar do crescimento do interesse pelo tema, boa parte dos frameworks revisados se concentra em processar dados já coletados — comentários de usuários, tickets de suporte, transcrições de reuniões, documentos de especificação — para depois extrair, classificar ou priorizar requisitos automaticamente.

Isso mostra algo importante sobre a produção acadêmica atual: o apoio da inteligência artificial costuma entrar depois da coleta de dados, e não antes dela, na concepção do próprio instrumento. Mesmo com o avanço dos modelos de linguagem de grande escala (LLMs), que ampliaram bastante as possibilidades de uso conversacional e generativo da IA em tarefas de engenharia de requisitos, a literatura consultada ainda não explora com profundidade seu uso como parceiro ativo na etapa de design do instrumento — ou seja, na elaboração colaborativa das perguntas, na revisão de sua clareza e no refinamento do roteiro antes mesmo do primeiro contato com o usuário final.

É nessa lacuna que este trabalho se posiciona. Em vez de restringir o uso da IA à análise das respostas depois de coletadas — tarefa já bem documentada por Siddeshwar, Alwidian e Makrehchi (2024) —, este estudo investiga seu uso desde a concepção do instrumento de elicitação, aplicado a uma técnica já consolidada e descrita por Alflen e Prado (2021), o questionário, e mantido ao longo de todo o ciclo seguinte de extração, especificação e validação dos requisitos que orientaram a primeira versão do sistema.

ESTUDO DE CASO

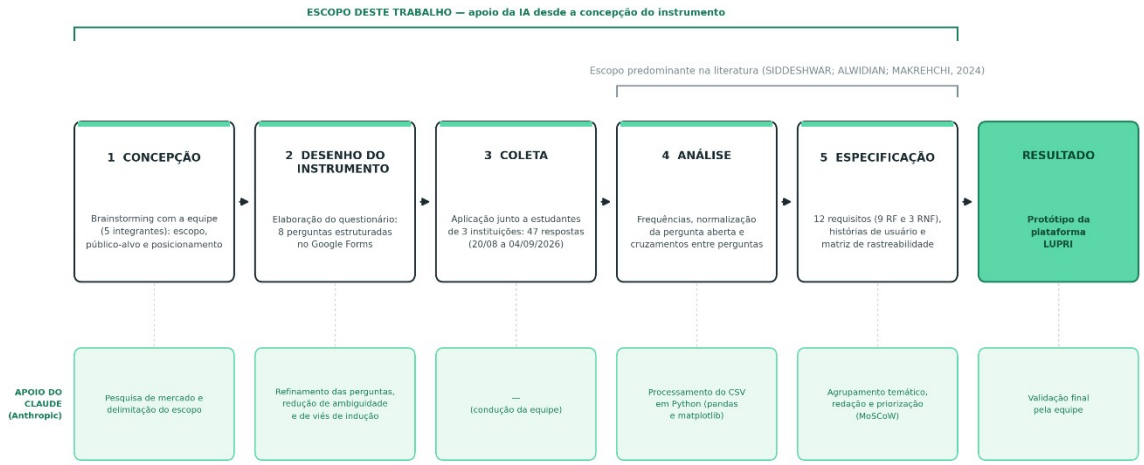
O estudo de caso apresentado neste trabalho tem caráter descritivo e qualitativo, e documenta todo o processo de elicitação de requisitos até a especificação da primeira versão da plataforma Lupri, começando na concepção dos instrumentos de coleta e chegando à extração das informações que orientaram o desenvolvimento. Nesse projeto, diferente do que é documentado por Siddeshwar, Alwidian e Makrehchi (2024) — IA apenas para análise de dados —, utilizamos o Claude (assistente de inteligência artificial da Anthropic) desde a primeira etapa, como ferramenta de suporte para a elaboração de questionários e entrevistas, pesquisa de mercado para entender onde o Lupri melhor se encaixa e análise dos resultados das técnicas de elicitação aplicadas.

O Lupri é um aplicativo de pesquisa acadêmica voltado a estudantes de graduação. Sua primeira versão organiza-se em sete passos: o usuário digita o tema do trabalho; o aplicativo busca artigos em bases acadêmicas reconhecidas, filtrando por origem; o usuário seleciona os que interessam e os guarda numa biblioteca pessoal; a referência em ABNT é gerada automaticamente no momento em que o artigo é salvo; dentro de cada artigo, um modelo de linguagem destaca os trechos mais relevantes para o tema digitado; o usuário decide, trecho a trecho, o que aproveitar; e, se quiser, solicita um resumo orientado ao seu tema de pesquisa, e não ao artigo como um todo.

Antes de qualquer coleta com usuários, a equipe conduziu, entre 8 e 16 de agosto, um levantamento das soluções já disponíveis, também com apoio do Claude. O mapeamento identificou três grupos. O primeiro reúne as ferramentas de inteligência artificial de uso geral, como o ChatGPT e o Gemini, que são o recurso ao qual o estudante comum de fato recorre e cuja fraqueza central é a procedência, já que podem apresentar referências inexistentes. O segundo é formado por soluções parciais, cada uma resolvendo uma etapa isolada do trabalho: o Google Acadêmico na busca, o Zotero e o Mendeley na gestão de referências e o Connected Papers no mapeamento de obras relacionadas. O terceiro é o das ferramentas com proposta equivalente à do Lupri, representado pelo Elicit, apontado como insatisfatório quanto ao idioma, ao custo e à clareza dos resultados.

A lacuna que restou do levantamento é a de uma ferramenta em português, de baixo custo, com fontes verificáveis e fluxo integrado do tema até a citação pronta. Ainda assim, o próprio relatório registrou duas limitações que orientaram a etapa seguinte. A primeira é que o mapeamento não foi exaustivo, restando ferramentas a verificar. A segunda, e mais relevante, é que toda a evidência sobre a dor do usuário vinha de uma única pessoa, com perfil de pesquisa mais avançado que o do público-alvo. Dessa constatação nasceu a hipótese que o questionário foi desenhado para testar: a de que a dificuldade de busca é comum e intensa entre os graduandos em geral, e não particular a quem idealizou o produto.

Imagem 1 - Processo de elicitação de requisitos do projeto



Fonte: Elaborada pelos autores com auxílio de inteligência artificial (Claude, da Anthropic), 2026.

MÉTODO

A técnica escolhida para a coleta foi o questionário que, na classificação de Alflen e Prado (2021), é de origem individual e se mostra indicada quando se pretende alcançar um número grande de stakeholders em pouco tempo e a baixo custo. Acontece que, como as próprias autoras ressaltam, ele carrega uma fraqueza conhecida: por não permitir interação direta com o respondente, tende a gerar informações rasas sobre o contexto e as motivações por trás das respostas. Foi justamente essa limitação que guiou as decisões da equipe e definiu o momento em que a inteligência artificial entrou no processo: não depois da coleta, como é mais comum na literatura consultada, mas antes dela, ainda na concepção do instrumento.

A primeira versão do questionário foi redigida integralmente pela equipe, em 16 de agosto, a partir das definições fixadas no brainstorming, e continha seis perguntas. Essa versão foi, então, submetida ao Claude, que atuou como revisor crítico do instrumento antes de qualquer contato com os respondentes. O Quadro 1 compara as duas versões e chama a atenção para três naturezas distintas de ajuste.

Quadro 1 - Comparação entre a versão inicial e a versão revisada do instrumento

Versão inicial (equipe)	Versão final (após revisão com apoio da IA)	Natureza do ajuste
"Como você pesquisa hoje quando precisa de referência para um trabalho?" (sem alternativas)	Mesma pergunta, com cinco alternativas fechadas (Google, Google Acadêmico, biblioteca física, sites/PDFs conhecidos, colegas/professores) e campo "Outro"	Fechamento de alternativas: torna as respostas comparáveis e quantificáveis, preservando o registro do não previsto
"Quanto tempo você gasta procurando o trecho certo em um livro/PDF?"	Removida. A dificuldade passou a ser uma das alternativas da pergunta sobre obstáculos	Eliminação de pressuposto: a pergunta original assumia que o respondente procura trechos em livros e PDFs, comportamento que ainda não havia sido verificado
"Você costuma usar IAs (Google, ChatGPT etc.) para gerar respostas prontas em trabalhos?"	"Você costuma usar IA para te ajudar na pesquisa de fontes/referências em trabalhos acadêmicos?"	Remoção de viés de indução: a expressão "respostas prontas" carrega juízo de valor e tende a provocar subnotificação do uso real
"Você acha que isso prejudica seu aprendizado/pesquisa real?"	Removida	Descarte de pergunta de opinião: mede julgamento moral do respondente, não comportamento, e não gera requisito
"Se existisse uma ferramenta ideal, o que ela deveria fazer?" (aberta)	"O que mais te atrapalha na hora de pesquisar pra um trabalho acadêmico?" (fechada)	Inversão de solução para problema: transfere ao respondente a descrição da dor, e não o desenho da solução
—	Quatro perguntas acrescentadas: meio utilizado, critério que guia a busca, origem dos materiais e escala de facilidade (1 a 5)	Ampliação de cobertura: acrescenta dimensões de contexto e uma medida de percepção comparável

Fonte: elaborado pelos autores com auxílio de inteligência artificial (Claude, da Anthropic), 2026.

O primeiro tipo de ajuste diz respeito ao fechamento das alternativas. Perguntas que, na versão inicial, não ofereciam opções, ganharam listas fechadas acompanhadas de campo "Outro", garantindo respostas comparáveis e quantificáveis sem que se perdesse o registro daquilo que não havia sido previsto. O segundo tipo trata da remoção de vieses: a pergunta sobre uso de IA, por exemplo, falava em "gerar respostas prontas", expressão que carrega juízo de valor e que, muito provavelmente, levaria os respondentes a subnotificar o uso real da ferramenta. Por fim, o terceiro tipo inverte a lógica da pergunta final, que pedia ao usuário o desenho da solução ideal e passou a questionar, de forma fechada, qual é a sua maior dificuldade. Vale ressaltar que essa inversão é a que mais se aproxima do que recomenda a literatura de elicitação: cabe ao respondente descrever o problema, e ao analista, propor a solução.

Além dos ajustes, quatro perguntas foram acrescentadas (meio utilizado, critério que guia a busca, origem dos materiais e uma escala de facilidade de 1 a 5), de modo que o instrumento passou de seis para oito perguntas. O questionário final foi publicado no Google Forms e ficou aberto entre 20 de agosto e 4 de setembro de 2026, recebendo 47 respostas completas. A divulgação se deu por grupos de WhatsApp aos quais a equipe tinha acesso, o que caracteriza uma amostra por conveniência e explica tanto a concentração de 91% das respostas em dois dias quanto o peso de um único curso na composição final.

As respostas foram exportadas em formato CSV e processadas com apoio do Claude, através da execução de código Python com as bibliotecas pandas e matplotlib. O tratamento envolveu a normalização da pergunta aberta de identificação, que recebeu grafias variadas para uma mesma instituição; a contagem independente de cada alternativa nas perguntas de múltipla escolha, com percentuais sempre calculados sobre o total de 47 respondentes; o agrupamento das respostas equivalentes registradas no campo "Outro"; e, por fim, o cruzamento entre perguntas. É importante ressaltar que a IA operou como ferramenta de apoio em todas essas etapas: a interpretação dos achados e a validação dos requisitos permaneceram sob responsabilidade da equipe.

O trabalho organizou-se em seis frentes: pesquisa de mercado, elaboração do instrumento, aplicação em campo, análise dos dados, identidade visual e redação do artigo. A elaboração do instrumento e a redação couberam ao grupo inteiro, enquanto as demais ficaram sob responsabilidade de duplas ou de um integrante. Parte do trabalho correu de forma assíncrona, de modo que mais de um integrante operou a ferramenta de IA, e as divergências de escopo foram resolvidas por consenso, após cada um apresentar sua leitura do problema.

O cronograma executado foi o seguinte: o brainstorming ocorreu em 6 de agosto de 2026, presencialmente, com os cinco integrantes; a pesquisa de mercado correu entre 8 e 16 de agosto e serviu para validar as definições da sessão anterior; a primeira versão do questionário foi redigida em 16 de agosto; a revisão do instrumento com apoio da IA ocorreu em 19 e 20 de agosto, e o formulário foi publicado nesta última data; a coleta seguiu até 4 de setembro; a análise foi conduzida em 5 de setembro; e a lista final de requisitos foi validada em 15 de setembro por três integrantes que não haviam participado da análise.

DESENVOLVIMENTO E RESULTADOS

Os 47 respondentes são estudantes de ensino superior de três instituições, sendo elas Fatec (47%), UNIP (36%) e Unianchieta (17%), distribuídos por doze cursos e um respondente que não informou o curso. O maior grupo individual é o de Fisioterapia da UNIP, com 17 respostas (36%), enquanto os cursos de tecnologia da Fatec somam 16 (34%). Chama a atenção que a amostra tenha extrapolado a turma dos autores e alcançado as áreas de saúde, exatas e humanas, o que sugere que as dificuldades relatadas não são exclusividade de um campo do conhecimento.

Sobre o comportamento de busca, o primeiro dado que se destaca é que a pesquisa começa pelo assunto: 94% dos respondentes são guiados pelo tema do trabalho e apenas 9% partem de um autor ou obra que já conhecem. A busca geral do Google é o caminho mais usado (68%), à frente do Google Acadêmico (57%), enquanto a biblioteca física aparece em apenas 9%. O celular é o meio predominante, usado por 79% dos estudantes, dos quais 30% pesquisam exclusivamente por ele. Os materiais, por sua vez, vêm sobretudo de sites e artigos online (81%) e de PDFs e slides enviados pelo professor (77%), ou seja, boa parte do conteúdo já está com o aluno, espalhado em arquivos, antes mesmo de a busca começar. Por fim, o uso de inteligência artificial já está incorporado à rotina: 87% recorrem a ela sempre ou às vezes na busca de fontes.

Entre as dificuldades, achar fonte confiável se destaca isoladamente, marcada por 81% dos respondentes, quase o dobro da segunda colocada, a formatação de citações e referências em ABNT (43%), seguida por localizar o trecho específico dentro do material (36%) e pela falta de tempo (23%).

Todavia, o achado mais relevante não veio de nenhuma pergunta isolada, e sim do cruzamento entre elas. Embora 81% relatem dificuldade em achar fonte confiável, apenas 4% avaliam como difícil encontrar o material certo na escala de 1 a 5, cuja média ficou em 3,36. A contradição é apenas aparente e admite uma leitura direta: encontrar algum material é fácil, difícil mesmo é saber se ele merece confiança. O problema do estudante, portanto, não é a escassez de conteúdo, mas o excesso de conteúdo sem filtro de qualidade. Um segundo cruzamento reforça esse diagnóstico: entre os 41 respondentes que usam IA com alguma frequência, 33 (80%) continuam apontando a confiabilidade como principal obstáculo, proporção praticamente idêntica à da amostra geral. Ou seja, a IA acelerou a busca, mas não resolveu a insegurança quanto à validade da fonte.

Esse achado produziu o efeito mais importante de todo o processo: a revisão da hipótese que sustentava o produto. No brainstorming, o Lupri havia sido definido como um buscador acadêmico

capaz de devolver o trecho exato do material, formulação que colocava a localização do trecho como dor central do estudante. O levantamento de mercado já havia relativizado essa ordem, ao colocar a confiabilidade das fontes entre as dificuldades principais, mas apoiado na percepção de uma única pessoa. Foi o questionário que a resolveu com dado: o trecho foi apontado por apenas 36% dos respondentes, menos da metade do peso atribuído à confiabilidade da fonte. É importante notar, todavia, que a funcionalidade não foi descartada: ela permaneceu no escopo da primeira versão, agora subordinada a uma etapa anterior de filtragem por origem acadêmica e de geração automática da referência. Dito isso, a elicitação não derrubou a ideia, e sim reordenou suas prioridades, o que é, em si, uma evidência do valor do processo: sem ela, o protótipo teria sido construído com o eixo invertido.

Da análise resultaram doze requisitos (nove funcionais e três não funcionais), priorizados pelo método MoSCoW (sigla de Must, Should, Could e Won't, ou seja, essencial, importante, desejável e fora de escopo) de acordo com a proporção de respondentes que sustenta cada um e organizados numa matriz de rastreabilidade que vincula cada requisito às perguntas que lhe deram origem. O Quadro 2 apresenta aqueles classificados como essenciais; os demais são referidos adiante por código e descrição.

Quadro 2 - Requisitos essenciais (Must) e evidência que os sustenta

ID	Requisito	Evidência
RF01	Permitir buscar referências a partir de um tema descrito em linguagem natural.	94% são guiados pelo tema do trabalho
RF02	Exibir indicador de confiabilidade para cada fonte (periódico revisado por pares, repositório institucional, site comum).	81% têm dificuldade com fonte confiável
RF03	Gerar automaticamente a referência de cada fonte no padrão ABNT.	43% relatam dificuldade com ABNT
RF08	Oferecer assistente de IA que sugere fontes sempre acompanhadas de link para o original.	87% já usam IA; 80% destes mantêm a dor de confiabilidade
RNF01	Interface mobile-first, com todas as funções utilizáveis no celular.	79% pesquisam pelo celular; 30% apenas por ele
RNF03	O assistente não deve exibir referência sem fonte verificável.	Cruzamento entre uso de IA e confiabilidade

Fonte: elaborado pelos autores com axílio de inteligência artificial (Claude, da Anthropic), 2026.

O recorte da primeira versão segue essa ordenação. Os sete passos descritos na abertura desta seção implementam diretamente os requisitos essenciais: a busca por tema (RF01), a filtragem por base acadêmica e o indicador de origem (RF02 e RF06), a geração da referência em ABNT (RF03), o destaque de trechos acompanhado da indicação da fonte (RF04 e RF08) e a interface pensada para o celular (RNF01). Além disso, a decisão de que cabe ao usuário aprovar cada trecho sugerido, e não o contrário, materializa o requisito de que nenhuma indicação da IA seja exibida sem fonte verificável (RNF03).

Ficaram para versões seguintes o upload de PDFs do próprio usuário (RF05), o suporte a normas de citação além da ABNT, a tradução e o resumo de artigos em inglês (RF09) e a integração com bibliotecas institucionais. Registre-se que o RF05 ficou de fora da primeira versão apesar da sustentação elevada no questionário, já que 77% dos respondentes declararam usar PDFs e slides enviados pelo professor: trata-se de uma decisão de escopo, e não de evidência, e é justamente a matriz de rastreabilidade que permite enxergar esse tipo de escolha e cobrá-la depois. Registre-se, por fim, que o resumo orientado ao tema, sétimo passo do fluxo, não deriva diretamente de nenhuma pergunta do

questionário: trata-se de decisão de projeto tomada a partir da combinação entre a dor de confiabilidade e a de localização do trecho, e deve ser validada nas entrevistas previstas.

Vale ressaltar que essa rastreabilidade é o principal resultado metodológico do estudo: nenhum dos doze requisitos foi formulado sem respaldo nas respostas, e nenhuma dificuldade relevante ficou sem requisito correspondente.

CONSIDERAÇÕES FINAIS

Este trabalho investigou o uso de inteligência artificial na elicitação de requisitos a partir de um ponto que a literatura consultada pouco explora: a concepção do instrumento de coleta, e não apenas o tratamento dos dados já coletados. O estudo de caso do Lupri mostrou que essa antecipação produz efeito verificável. Das seis perguntas redigidas pela equipe, três foram reformuladas e duas descartadas, com quatro acréscimos, em ajustes de três naturezas que a literatura reconhece como determinantes para a qualidade do dado: o fechamento de alternativas, a remoção de viés de indução e a inversão da pergunta de solução para problema. Aplicado o instrumento, as 47 respostas revelaram, por cruzamento, um achado que nenhuma pergunta isolada produziria: a dificuldade do estudante não está em encontrar conteúdo, e sim em confiar naquilo que encontra. Esse resultado reordenou as prioridades do produto e submeteu a hipótese original da equipe a um teste que ela não enfrentaria caso o protótipo fosse construído a partir da intuição de seus autores. A inteligência artificial, portanto, não substituiu o julgamento da equipe, mas antecipou o momento em que esse julgamento pôde ser exercido sobre evidência.

Os achados, todavia, vêm de uma amostra por conveniência, com peso elevado de um único curso, e não comportam generalização. É por isso que a etapa seguinte já está definida: entrevistas de aprofundamento, técnica de origem mista na classificação de Alflen e Prado (2021), conduzidas com o mesmo apoio de IA empregado até aqui. Elas devem investigar o que o estudante entende por fonte confiável, validar o perfil de usuário que emerge das respostas e testar as telas dos requisitos essenciais com parte dos respondentes.

REFERÊNCIAS

ALFLEN, Naiara Crislaine; PRADO, Edmir Parada Vasques. Técnicas de elicitação de requisitos no desenvolvimento de software: uma revisão sistemática da literatura. **Atoz**: novas práticas em informação e conhecimento, [S.L.], v. 10, n. 1, p. 39, 22 jan. 2021. Universidade Federal do Paraná.

http://dx.doi.org/10.5380/atoz.v10i1.77393. Disponível em: https://revistas.ufpr.br/atoz/article/view/77393/42855. Acesso em: 23 ago. 2026;

CHENG, Haowei et al. Generative AI for Requirements Engineering: a systematic literature review. **Software: Practice and Experience**, [S.L.], v. 56, n. 2, p. 141-170, 2026. Wiley. http://dx.doi.org/10.1002/spe.70029. Disponível em: https://arxiv.org/abs/2409.06741. Acesso em: 03 set. 2026;

FERRARI, Alessio; SPOLETINI, Paola; GNESI, Stefania. Ambiguity and tacit knowledge in requirements elicitation interviews. **Requirements Engineering**, [S.L.], v. 21, n. 3, p. 333-355, 2016. Springer. http://dx.doi.org/10.1007/s00766-016-0249-3. Disponível em: https://link.springer.com/article/10.1007/s00766-016-0249-3. Acesso em: 03 set. 2026;

KORN, Alexander; GORSCH, Samuel; VOGELSANG, Andreas. LLMREI: automating requirements elicitation interviews with LLMs. **arXiv**, [S.L.], jul. 2025. Preprint. Disponível em: https://arxiv.org/abs/2507.02564. Acesso em: 10 set. 2026;

MAJEED, Esra Zuhair. Intelligent Technique for Optimizing Requirements Elicitation in Software Engineering Projects. **Sistemasi: Jurnal Sistem Informasi**, [S.L.], v. 15, n. 8, p. 3350-3367, 2026. http://dx.doi.org/10.32520/stmsi.v15i8.6850. Disponível em: https://sistemasi.ftik.unisi.ac.id/index.php/stmsi/article/view/6850. Acesso em: 18 set. 2026;

SHEN, Yuchen; SINGHAL, Anmol; BREAUX, Travis. Requirements Elicitation Follow-Up Question Generation. In: IEEE INTERNATIONAL REQUIREMENTS ENGINEERING CONFERENCE, 33., 2025. **Anais** [...]. [S.L.]: IEEE, 2025. Disponível em: https://arxiv.org/abs/2507.02858. Acesso em: 23 set. 2026;

SIDDESHWAR, Vaishali; ALWIDIAN, Sanaa; MAKREHCHI, Masoud. A Systematic Review of AI-Enabled Frameworks in Requirements Elicitation. **IEEE Access**, [S.L.], v. 12, p. 154310-154336, 2024. Institute of Electrical and Electronics Engineers (IEEE). http://dx.doi.org/10.1109/access.2024.3475293. Disponível em: https://ieeexplore.ieee.org/document/10706210. Acesso em: 23 ago. 2026.

ZADENOORI, Mohammad Amin et al. Large Language Models (LLMs) for Requirements Engineering (RE): a systematic literature review. **arXiv**, [S.L.], set. 2025. Preprint. Disponível em: https://arxiv.org/abs/2509.11446. Acesso em: 18 set. 2026.